

# 叶片图像特征提取与识别技术的研究

王晓峰<sup>1,2</sup> 黄德双<sup>1</sup> 杜吉祥<sup>1</sup> 张国军<sup>1</sup>

<sup>1</sup>(中国科学院合肥智能机械研究所,合肥 230031)

<sup>2</sup>(合肥学院计算机科学与技术系,合肥 230022)

E-mail: xfwang@iim.ac.cn

**摘要** 文章介绍了一种基于叶片图像的形状特征对叶片进行识别的方法。首先对叶片图像进行预处理并且提取出叶片的轮廓,然后利用轮廓计算得到叶片的矩形度、圆形度、偏心率等8项几何特征和7个图像不变矩,同时在文中提出了一种新的移动中心超球分类器,利用其对得到的形状特征进行分类从而实现了20多种植物叶片的快速识别,并且平均识别率达到了92%。

**关键词** 叶片图像 图像预处理 特征提取 移动中心超球分类器

文章编号 1002-8331-(2006)03-0190-04 文献标识码 A 中图分类号 TP391

## Feature Extraction and Recognition for Leaf Images

Wang Xiaofeng<sup>1,2</sup> Huang Deshuang<sup>1</sup> Du Jixiang<sup>1</sup> Zhang Guojun<sup>1</sup>

<sup>1</sup>(Institute of Intelligent Machines, Chinese Academy of Sciences, Hefei 230031)

<sup>2</sup>(Department of Computer Science and Technology, Hefei University, Hefei 230022)

**Abstract:** This paper introduces a method of recognizing leaf images based on shape features. Firstly, we apply image pre-processing techniques to get the contours of the leaves. Then we extract eight geometric features including rectangularity, circularity, eccentricity, etc., and seven moment invariants from leaves' contours for classification. Finally we propose a new moving center hypersphere classifier to address these shape features. As a result there are more than 20 kinds of plant leaves successfully recognized. The average correct recognition rate is up to 92 percent.

**Keywords:** leaf images, image pre-processing, feature extraction, moving center hypersphere classifier

## 1 引言

在地球上的一切生物中,植物和人类以及环境的关系最为密切。大量的植物维持着地球大气中氧气和二氧化碳的平衡,植物也是人类生产和生活所必需的资源。但近些年来人类的各种生产活动严重地破坏了生态环境,从而造成植物在数量上的减少甚至物种上的灭绝。值得庆幸的是,人类已经意识到这一危机,从而渐渐开始迈出了保护植物的步伐。

对植物进行分类研究是对其进行保护的第一步也是很重要的一步,但由于人类认知能力有限以及地球上数量众多的植物种类,要做到准确和快速地识别手中的植物是非常困难的。随着近些年来计算机技术的不断发展,图像处理与识别技术在农业中也得到了一定的应用,因此可以考虑使用图像处理技术、模式识别技术且辅助以计算机图像获取设备实现对植物的快速识别。

从植物分类的角度来看,识别一种植物最直接有效和最简单的方法就是从它的叶片着手,而且叶片也是比较容易采集到的,通常在植物学里叶片的形状、颜色和脉络都可以拿来作为分类依据,而我们则把重点放在提取叶片的形状特征作为识别依据上。利用我们提出的移动中心超球分类器对提取的特征进行分类,可以实现对部分叶片的快速和成功的识别。

## 2 图像预处理

整个叶片图像识别的流程如图1所示。首先我们把采集到的叶片通过数码相机或者扫描仪制成数字图像,然后对图像进行预处理,这其中主要包括阈值分割、形态学处理和轮廓提取三个环节,接下来利用提取出来的轮廓计算叶片形状特征,并使用移动中心超球分类器对特征进行分类进而识别出叶片所属种类。




图1 叶片图像识别流程图

### 2.1 阈值分割

在这里分割的目的是为了把叶片与其背景分开并形成二值图像,以便于其后进行的轮廓提取和形状特征的计算。由于不同种类叶片的颜色并不一样,因此在转成灰度图像后很难用一个统一的灰度门限进行分割,因此我们必须针对每一幅图像计算其灰度门限。根据对叶片图像灰度直方图的观察,我们发现叶片与背景的灰度级存在着明显的差异,根据这一特点我们选择了计算较为方便的迭代阈值选择法<sup>[4]</sup>来计算灰度门限,具体步骤如下:

**作者简介:** 王晓峰,男,硕士研究生,主要研究方向:计算机图像处理与识别。黄德双,男,教授,博士生导师。杜吉祥,男,博士研究生。张国军,男,硕士研究生。

(1) 求出整幅图像的最大灰度值和最小灰度值, 分别记为  $G_{\max}$  和  $G_{\min}$ , 令初始灰度门限  $T_0 = \frac{G_{\max} + G_{\min}}{2}$ ;

(2) 根据灰度门限  $T_k$  将图像分割为前景和背景, 分别求出两者的平均灰度值  $Z_1$  和  $Z_2$ ;

(3) 求出新灰度门限  $T_{k+1} = \frac{Z_1 + Z_2}{2}$ ;

(4) 若  $T_k = T_{k+1}$ , 则  $T_k$  即为灰度门限, 否则到第(2)步, 继续迭代计算。

## 2.2 形态学处理

迭代法可以很好地完成二值分割工作, 但我们也发现某些植物叶片可能遭受过虫子的侵蚀(图 2(a)), 从而在分割后的叶片目标内部存在小的孔洞(图 2(b)), 影响轮廓的提取, 因此这部分图像在二值化后需要进一步处理, 为了保持叶片图像的形状特性以及边缘的清晰, 我们使用了数学形态学里的闭运算, 即先进行膨胀运算, 再进行腐蚀运算, 这样经过一次或两次处理后就消除了叶片内部的小孔洞(图 2(c))。同时在实验中我们发现叶片的叶柄由于长度参差不齐, 对形状特征的提取会造成一定的影响从而影响识别率, 因此必须在二值化后的图像里消除叶片的叶柄, 这里可以使用形态学处理中的开运算, 即先进行腐蚀运算, 再进行膨胀运算, 图 2(d) 即为消除叶柄后的二值化叶片图像。




图 2 受侵蚀叶片预处理

## 2.3 轮廓提取

由于叶片的轮廓是叶片自身的像素子集, 且轮廓同样含有丰富的形态信息, 通过轮廓来计算形状特征比通过叶片本身来说计算量要小一些, 在大批量的叶片样本处理情况下更是明显节约了时间, 因此需要进一步提取叶片的轮廓, 我们采用了轮廓跟踪法来找出轮廓。可以看到分割后的图像里叶片目标是由 1 像素构成的, 因此需要寻找由 1 像素构成的轮廓点, 对于 1 像素点我们考虑跟踪其 8 个方向的邻域, 同时采用弗里曼链码法<sup>[9]</sup>对找到的轮廓点进行编码。

具体跟踪算法步骤如下:

(1) 按照从上到下, 从左到右的顺序扫描图像, 得到的第一个像素值为 1 的点定为起始点, 如果找不到起始点则算法结束;

(2) 按逆时针顺序从当前点右边开始搜索其 8 个方向的邻域点, 如果找到一个未曾搜索过的 1 像素点, 并且该点上下左右 4 个方向含有 0 像素点, 则把当前点置为该邻域点, 记录下相应的链码值, 重复该过程直到找到初始点。

图 2(e) 显示了对图 2(d) 中叶片轮廓的跟踪结果。

## 3 特征提取

通常可用于植物叶片分类的图像特征有很多, 比如形状特征、颜色特征和纹理特征等, 根据植物分类的相关理论, 叶片的形状特征是判断叶片所属种类的最重要和最有效的依据, 因此我们首先考虑提取叶片的几何形状特征用于分类。根据我们采集的叶片来看, 不同种类叶片的形状存在着较大的差异, 即使是同一种叶片其大小比例也可能有所不同, 这样周长、面积、纵轴长、横轴长等常用的绝对值特征就不太适合作为分类依据, 应该考虑使用一些相对值特征, 在这里我们可以利用叶片轮廓得到一些形状描述(图 2(f) 所示), 包括最小包围盒(bounding-box)、凸包(convex hull)、外切圆(excicle)和内切圆(inscribed circle)等, 并通过它们计算得到了 8 项相对值几何特征: 纵横轴比、矩形度、面积凹凸比、周长凹凸比、球状性、圆形度、偏心率、形状参数。

(1) 纵横轴比 (Aspect Ratio) 是叶片最小包围盒的长宽比值:

$$\text{Aspect Ratio} = \frac{\text{length}_{\text{bounding-box}}}{\text{width}_{\text{bounding-box}}} \quad (1)$$

(2) 矩形度 (Rectangularity) 是叶片面积与叶片最小包围盒面积的比值:

$$\text{Rectangularity} = \frac{\text{Area}_{\text{object}}}{\text{Area}_{\text{bounding-box}}} \quad (2)$$

(3) 面积凹凸比 (Area Convexity) 是叶片面积与叶片凸包面积的比值:

$$\text{Area Convexity} = \frac{\text{Area}}{\text{Convex Area}} \quad (3)$$

(4) 周长凹凸比 (Perimeter Convexity) 是叶片周长与叶片凸包周长的比值:

$$\text{Perimeter Convexity} = \frac{\text{Perimeter}}{\text{Convex Perimeter}} \quad (4)$$

(5) 球状性 (Sphericity) 是叶片面积与叶片凸包周长的计算值:

$$\text{Sphericity} = \frac{4\pi \times \text{Area}}{\text{Convex Perimeter}^2} \quad (5)$$

(6) 圆形度 (Circularity) 是叶片内切圆半径与外切圆半径的比值:

$$\text{Circularity} = \frac{R_{\text{inscribed circle}}}{R_{\text{excicle}}} \quad (6)$$

(7) 偏心率 (Eccentricity) 是叶片自身长轴与短轴的比值:

$$\text{Eccentricity} = \frac{\text{Axis Length}_{\text{long}}}{\text{Axis Length}_{\text{short}}} \quad (7)$$

(8) 形状参数 (Form Factor) 是叶片面积和周长的计算值:

$$\text{Form Factor} = \frac{4\pi \times \text{Area}}{\text{Perimeter}^2} \quad (8)$$

以上 8 项几何特征都具有旋转、平移和尺度不变性, 这些

特性对于叶片识别来说是非常重要的,表1即为图2(d)中叶片的8项几何特征数值。

表1 图2(d)中叶片的8项几何特征数值

纵横轴比	3.104
矩形度	0.599
面积凹凸比	0.888
周长凹凸比	1.087
球状性	0.258
圆形度	0.195
偏心率	2.696
形状参数	0.437

除了几何特征外,图像矩由于具有天然的旋转、平移和尺度不变性,也被广泛地应用在图像识别领域里,因此我们另外加入了M.K.Hu提出的7项Hu不变矩<sup>[6]</sup>作为识别特征,在这里我们采用了Chen提出的改进矩算法<sup>[7]</sup>来计算这7项Hu不变矩,算法如下:

Chen的 $p+q$ 级改进矩定义为:

$$M_{pq} = \int_C x^p y^q ds \quad (9)$$

其中 $p, q=1, 2, 3, \dots$ ,  $\int_C$ 是沿着闭合轮廓 $C$ 的线积分,  $ds = \sqrt{(dx)^2 + (dy)^2}$ 。在实际应用中我们可以采用其离散形式来近似计算:

$$M_{pq} = \sum_{(x,y) \in C} x^p y^q \quad (10)$$

同样中心矩 $\mu_{pq}$ 也可以近似计算为:

$$\mu_{pq} = \sum_{(x,y) \in C} (\bar{x}-x)^p (\bar{y}-y)^q \quad (11)$$

$$\bar{x} = \frac{M_{10}}{M_{00}} \quad \bar{y} = \frac{M_{01}}{M_{00}}$$

为了得到尺度不变性 $\mu_{pq}$ 可进一步正则化为:

$$\eta_{pq} = \frac{\mu_{pq}}{\mu_{00}} \quad (12)$$

其中正则化因子 $\gamma=p+q+1$ 。

利用正则化后的中心矩 $\eta_{pq}$ 我们就可计算出7个Hu不变矩,计算公式如下:

$$\begin{aligned} \phi_1 &= \eta_{20} + \eta_{02} \\ \phi_2 &= (\eta_{20} - \eta_{02})^2 + 4\eta_{11}^2 \\ \phi_3 &= (\eta_{30} - 3\eta_{12})^2 + (\eta_{03} - 3\eta_{21})^2 \\ \phi_4 &= (\eta_{30} + \eta_{12})^2 + (\eta_{03} + \eta_{21})^2 \\ \phi_5 &= (3\eta_{30} - 3\eta_{12})(\eta_{30} + \eta_{12})[(\eta_{30} + \eta_{12})^2 - 3(\eta_{21} + \eta_{03})^2] + \\ &\quad (3\eta_{21} - \eta_{03})(\eta_{21} + \eta_{03}) \times [3(\eta_{30} + \eta_{12})^2 - (\eta_{21} + \eta_{03})^2] \\ \phi_6 &= (\eta_{20} - \eta_{02})[(\eta_{30} + \eta_{12})^2 - (\eta_{21} + \eta_{03})^2] + \\ &\quad 4\eta_{11}(\eta_{30} + \eta_{12})(\eta_{21} + \eta_{03}) \\ \phi_7 &= (3\eta_{21} - \eta_{03})(\eta_{30} + \eta_{12})[(\eta_{30} + \eta_{12})^2 - 3(\eta_{21} + \eta_{03})^2] + \\ &\quad (3\eta_{12} - \eta_{30})(\eta_{21} + \eta_{03}) \times [3(\eta_{30} + \eta_{12})^2 - (\eta_{21} + \eta_{03})^2] \end{aligned} \quad (13)$$

表2为图2(d)中叶片以及对其旋转45°和缩小1倍后的7项Hu不变矩数值。

表2 图2(d)中原始叶片以及旋转缩小后的Hu不变矩数值

	原始叶片	旋转45°	缩小1倍
1	1.795 92e-001	1.797 98e-001	1.792 66e-001
2	5.834 03e-003	5.844 29e-003	5.799 81e-003
3	1.387 15e-004	1.481 40e-004	1.211 64e-004
4	3.670 16e-005	4.000 30e-005	3.185 44e-005
5	2.618 69e-009	3.079 43e-009	1.978 98e-009
6	2.797 58e-006	3.051 93e-006	2.420 26e-006
7	1.349 41e-011	1.392 68e-011	1.292 84e-012

这样对于每片叶片我们采用其8项几何特征和7项Hu不变矩作为分类特征,这15项特征均不随着叶片目标旋转、平移和尺度变化而变化。从表1和表2的数据可以看到一些特征在数量级上存在着较大的差异,比如纵横比和不变矩-3就相差4个数量级,而不变矩-1和不变矩-7之间更差着10个数量级,因此需要对各项特征进行归一化,我们使用公式(14)把各项特征值都归一化到[0,1]范围内。

$$E = \frac{E - E_{\min}}{E_{\max} - E_{\min}} \quad (14)$$

其中 $E$ 为特征值, $E_{\max}$ 为所有叶片样本数据中该项特征的最大值, $E_{\min}$ 为所有叶片样本数据中该项特征的最小值。

#### 4 移动中心超球分类器

由于叶片样本数量和我们选择的分类特征数目都比较多,这样在特征空间里特征向量的数量和维数都非常高,因此需要选用一种合理的分类器,既能保证较高的识别率也要尽量减少存储空间和计算时间,基于此我们提出了一种移动中心超球分类法,它是一种对参考样本进行压缩的方法,通过对样本数据的压缩处理,有效地减少了存储空间和计算时间,而且对识别正确率没有影响。它的基本思想是用超球来代表一簇点,我们知道一个样本在高维空间中就是一个点,一个类别就是对应于空间中的一个点集,因此我们可以运用一系列超球来拟合这些点所在的高维空间。该算法大体思想是对每种样本用若干个超球去逼近,并移动超球的中心同时努力扩大超球的半径使其包含尽可能多的样本点,从而减少存储的超球数量,最终实现用多个超球包含样本空间中所有的样本点。下面以一类样本点为例介绍移动中心超球分类器的训练步骤:

- (1)初始化超球标记 $k=1$ ,将所有样本点放到一个集合里;
- (2)在集合里面找到一个离集合内所有点的均值最近的点作为第 $k$ 个超球的初始中心点 $s$ ;
- (3)找到其他类里离中心点 $s$ 最近的点,定义其到中心点距离为它类最近距离,记为 $d_1$ ;
- (4)我们在以 $s$ 为中心点 $d_1$ 为半径的超球里找到本类中离 $s$ 最远的点,定义其到 $s$ 距离为本类最远距离,记为 $d_2$ ;
- (5)设第 $k$ 个超球的半径 $r = \frac{d_1 + d_2}{2}$ ;
- (6)在距中心点 $s$ 最近的 $m$ 个点里找在它类最近点的方向的反方向上的点,如果找到则把该点作为新的中心点并转第(4)步,否则继续下一步;
- (7)将集合里被超球所包围的点从集合里去掉了,如果集合内还有点则 $k=k+1$ ,转第(2)步;否则去除掉那些被其它超球所

包括的冗余超球,训练结束。

举个例子,假设某一类里有 40 个样本点,经过训练后可以用 4 个超球来覆盖原有 40 个样本点,这样需要存储的对象只有原来的  $\frac{1}{10}$ ,而识别时间也可以大大地缩短。

在识别的时候,我们以待识别样本点到超球外表面的距离为判断依据,判断准则为:

$$l = \operatorname{argmin}(d_i - r_i) \quad i \in \{1, 2, 3, \dots, k\} \quad (15)$$

其中  $k$  表示训练结束得到的超球总数,  $d_i$  表示待识别样本点到第  $i$  个超球的欧氏距离,  $r_i$  表示第  $i$  个超球的半径,  $l$  即为与待识别样本点距离最近的超球所在类的标记(如果待识别样本点正好位于一个超球的内部,那么它到该超球外表面的距离为负值)。

## 5 实验结果及分析

我们选取了银杏叶片、广玉兰叶片、桂花叶片、海桐叶片等 20 种植物叶片(图 3)来测试移动中心超球分类器的性能,每类叶片采集 20 个样本,其中随机选取 15 个作训练样本,剩余 5 个作测试样本,试验配置为:P4 2.4G 主频,80G 硬盘,256M 内存。图 4 为训练结束时各超球的半径,从图中横坐标的下标可以看出一共得到了 60 个超球。图 5 为以某片银杏叶片做测试时待识别样本点与各超球外表面的距离,可以看到该点与第 18 个超球的外表面距离最近,而该超球正好覆盖的是一部分银杏叶片的样本点。同时我们也用同一批数据对最近邻分类器、4-近邻分类器以及 BP 神经网络(输入节点数为 15,隐层节点数为 12,输出节点数为 20)进行了测试,表 3 列出了四种分类器的训练时间、识别时间、存储空间和平均识别率。



图 3 用来测试分类器性能的 20 种植物叶片




图 4 训练结束时各超球的半径




图 5 识别银杏叶片时样本点与各超球外表面的距离

从表 3 中我们可以看到训练过的移动中心超球分类器在识别时间上要比最近邻分类器和 4-近邻分类器短,并且前者的存储向量数比后面两者要小得多,而识别率只比后两者有微弱的下降。虽然移动中心超球分类器需要训练而其它两种不需要,但当对于一个具有庞大样本数量的工程而言,可以看出由于识别时间和存储空间上的优势,移动中心超球分类器是一个更好的选择。与 BP 神经网络对比可以看出 BP 网络基本上不需要什么存储空间,识别时间也比较短,但训练时间却比移动中心超球分类器长很多,而且随着样本数量的增加,BP 网络收敛速度会非常慢,同时有可能会陷入局部极小,因此移动中心超球分类器可能更加适合于实际应用下的应用。

表 3 四种分类器的性能对比

	训练时间/ms	识别时间/ms	存储向量数	平均识别率/%
最近邻分类器	/	2.9	300	92.6
4-近邻分类器	/	9.4	300	92.1
BP 神经网络	125	1.1	/	92.4
超球分类器	11.8	1.2	60	92.2

## 6 结论与展望

在这篇文章里我们提出了提取叶片的形状特征并且结合一种新的移动中心超球分类器对叶片进行识别的方法。文中介绍的方法已经成功地应用在我们开发的植物叶片识别软件系统 PLRS1.0 中,该系统使用 Visual C++ 6.0 开发,能够对银杏、广玉兰、桂花、海桐、黄芽、石楠等 20 多种植物的叶片实现预处理、特征提取和自动识别,并且平均识别率达到了 92%。下一步我们将把工作重点放在如何识别复杂环境下的植物叶片图像以及进一步地提高移动中心超球分类器的识别率上面。

(收稿日期:2005 年 4 月)

## 参考文献

1. Milan Sonka, Vaclav Hlavac, Roger Boyle. Image Processing, Analysis and Machine Vision[M]. Second Edition, Beijing: Posts & Telecom Press, 2002
2. 黄德双. 神经网络模式识别系统理论[M]. 北京: 电子工业出版社, 1996
3. 边肇祺, 张学工. 模式识别[M]. 北京: 清华大学出版社, 1999
4. T W Ridler, S Calvard. Picture Thresholding Using An Iterative Selection Method[J]. IEEE Transaction on System, Man and Cybernetics, 1978; 8(8): 630-632
5. H Freeman. On the encoding of arbitrary geometric configurations[J]. IRE Trans on Electronic Computers, 1961; EC-10: 260-268
6. M K Hu. Visual Pattern Recognition by Moment Invariants[J]. IRE Transaction Information Theory, 1962; 8(2): 179-187
7. Chaur-Chin Chen. Improved Moment Invariants for Shape Discrimination[J]. Pattern Recognition, 1993; 26(5): 683-686
8. 于新文, 沈佐锐, 高灵旺等. 昆虫图像几何形状特征的提取技术研究[J]. 中国农业大学学报, 2003; 8(3): 47-50
9. 徐昉, 邱道尹, 沈宪章. 粮仓害虫的特征提取与分类的研究[J]. 郑州工业大学学报, 2000; 21(4): 62-65
10. D S Huang. The local minima free condition of feedforward neural networks for outer-supervised learning[J]. IEEE Transaction on Systems, Man and Cybernetics, 1993; 28B(3): 477-480